Arquitetura de Dados Analíticos

Data Lake

Professor

Gustavo Dias
Mestre em Gestão e Desenvolvimento Regional

Consultor em Business Intelligence, com atuação em projetos na área da saúde e varejo.

Contatos:

p.gustavodias@gmail.com

https://www.linkedin.com/in/pgustavodias/

pgustavodias

Agenda de aula

- Correção comentada;
- Arquitetura de dados;
- Maturidade organizacional;
- Data Lake;
- MDW;
- Data Lakehouse.

.maturidade organizacional

O Desafio dos Dados: Muito Além do Volume

Volume
Escala massiva de Terabytes a Petabytes

Velocidade
De processamento em lote a streaming em tempo real

Valor
Transformar densidade de dados dispersos em insights preditivos

Variabilidade
Inconsistência de formatos e picos de frequência

Veracidade
Confiabilidade e qualidade de fontes dispersas

Variedade
Estruturados, Semi-estruturados e Não-estruturados

A Jornada da Maturidade de Dados

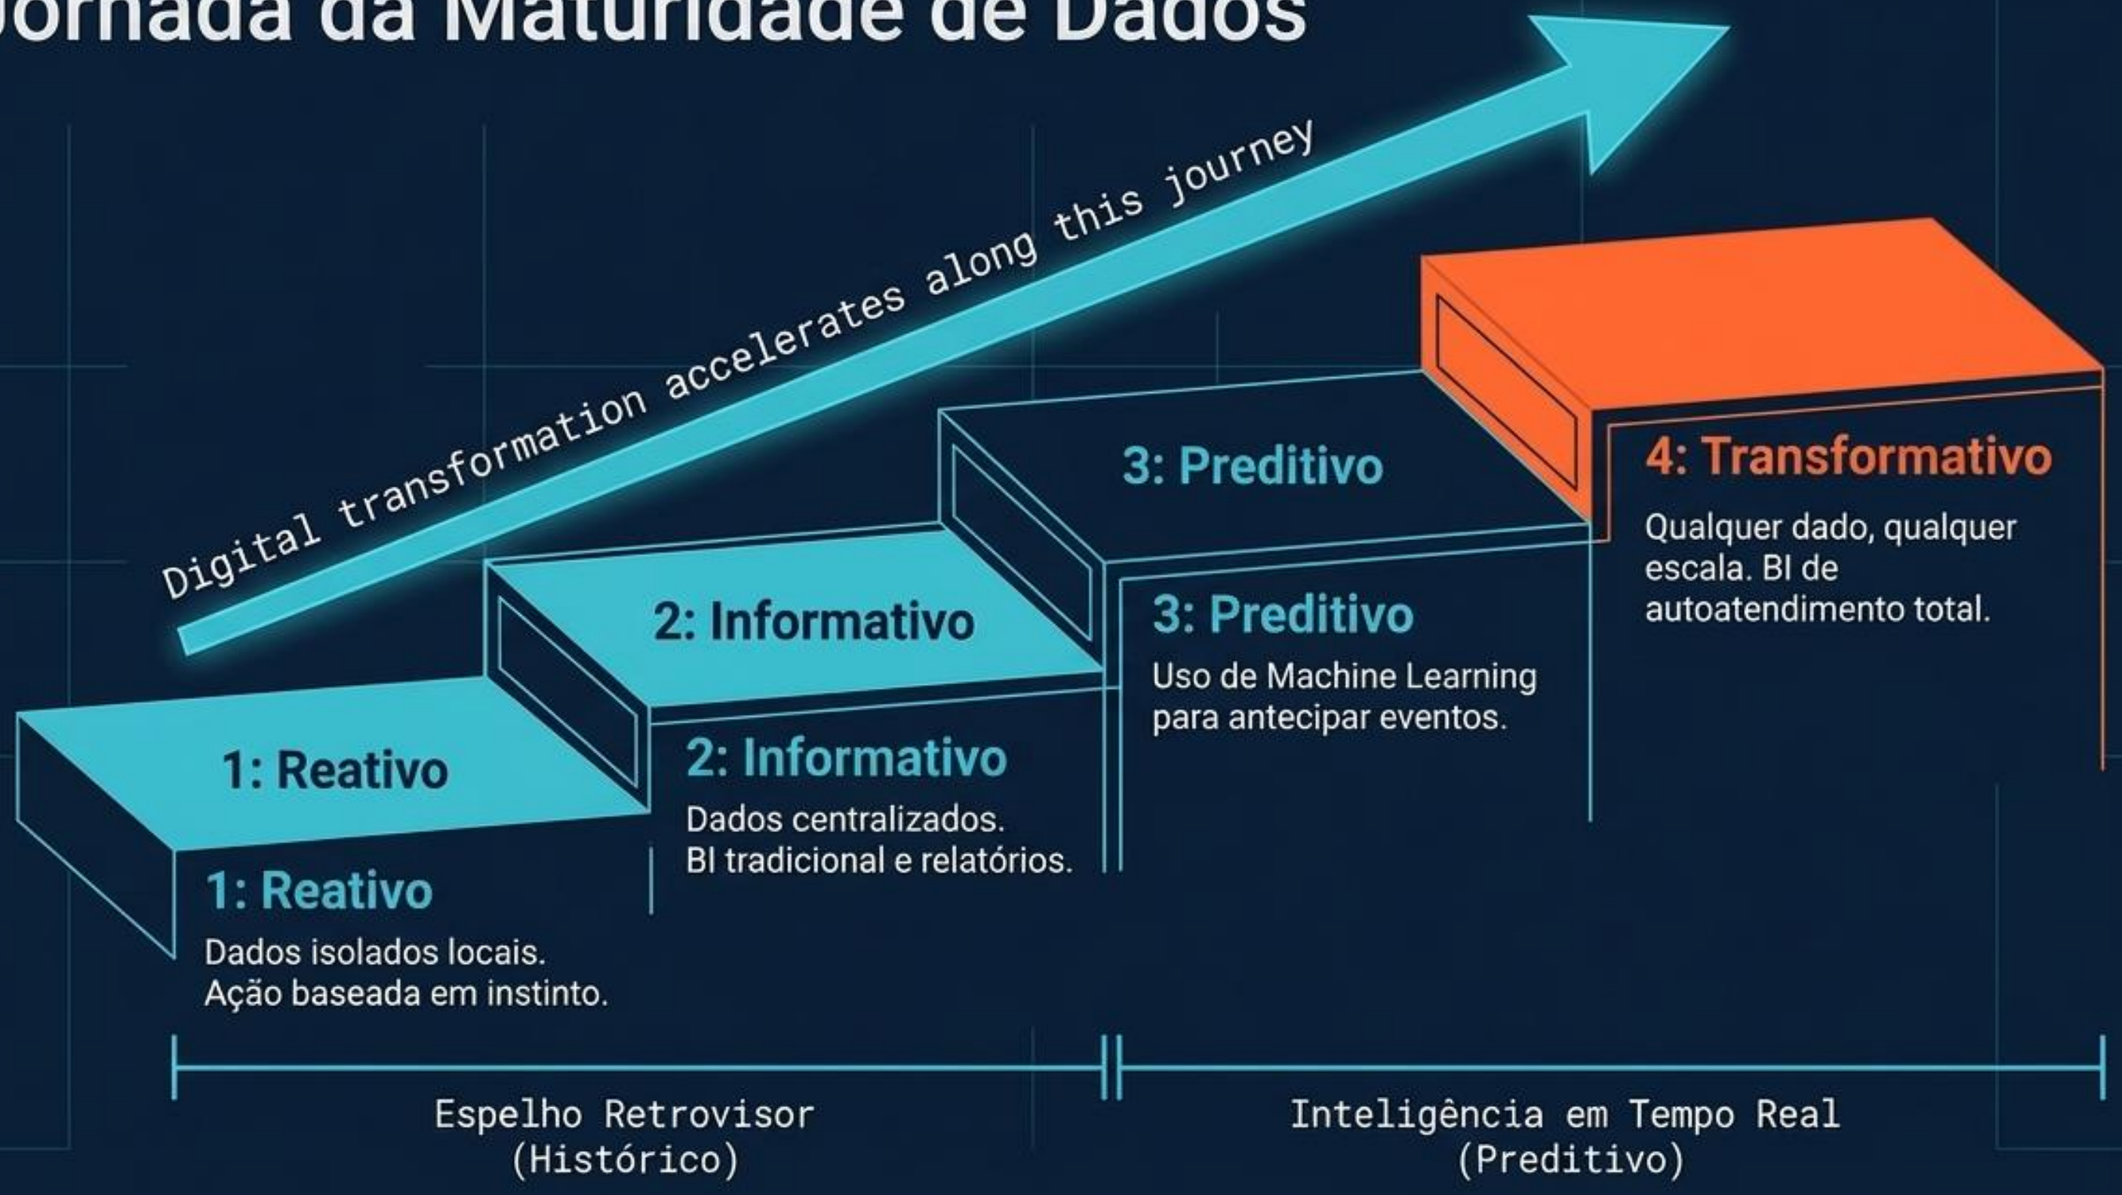

.arquitetura de dados

O Paradigma da Ingestão: Moldar Antes vs. Moldar Depois

Schema-on-Write (RDW)

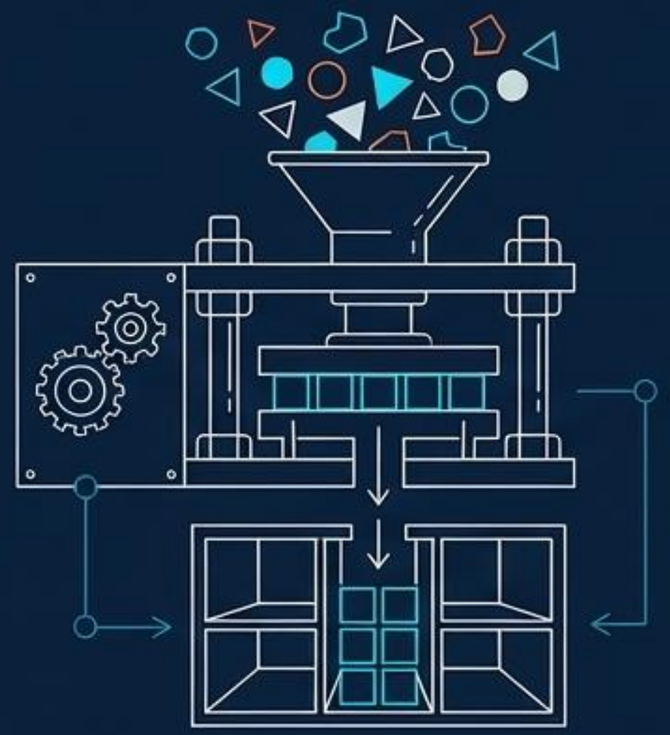

Consistência rígida. Requer modelagem prévia de tabelas e colunas. Ingestão lenta, leitura ultrarrápida.

Schema-on-Read (Data Lake)

Flexibilidade extrema. Armazena dados no formato bruto nativo. A estrutura é aplicada apenas no momento da consulta.

A Base Tradicional: Relational Data Warehouse (RDW)

Vantagens

- Suporte robusto a transações (ACID)
- Segurança e governança maduras
- Trilhas de auditoria
- Desempenho extremo para BI

Limitações

- Alto custo de armazenamento
- Dimensionamento rígido
- Incompatível com dados não-estruturados (vídeo, áudio)

A Resposta Escalável: Data Lake

A Ilusão da Bala de Prata

Prometido como o substituto barato do RDW, falhou ao exigir que analistas de negócios usassem Python/Spark para extrair relatórios. A produtividade foi destruída pela falta de estrutura.

O Novo Papel

Hoje, o Data Lake é a zona de Staging perfeita para preparação de dados brutos e treinamento de modelos de Machine Learning.

O Melhor dos Dois Mundos: Modern Data Warehouse (MDW)

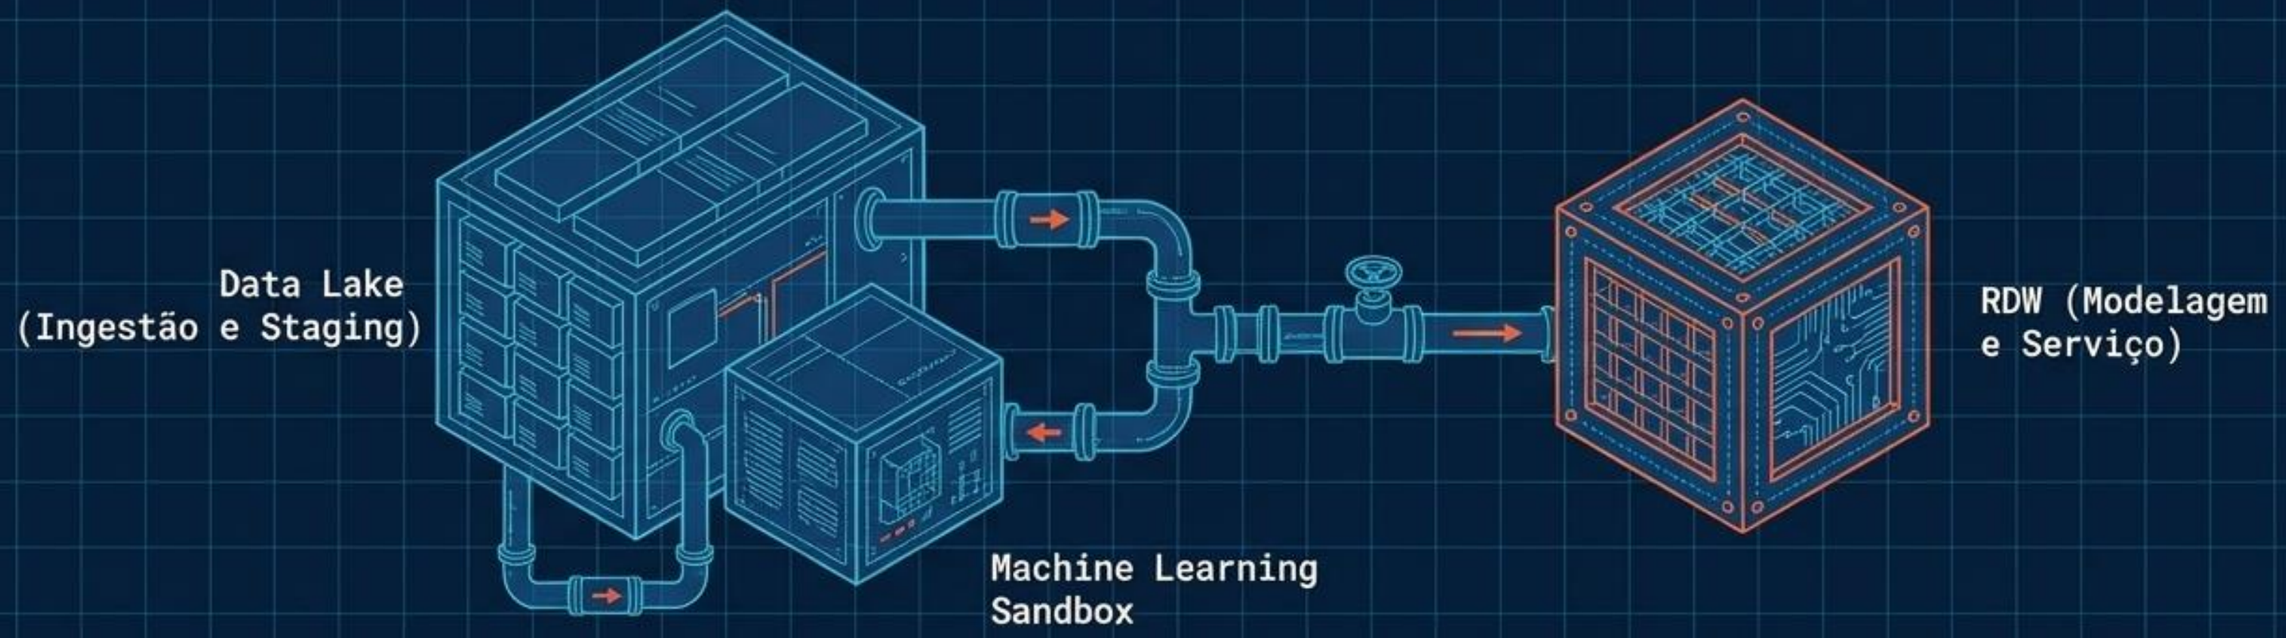

O Papel do Lake

Ingestão de todos os dados em formato bruto (Schema-on-read). Baixo custo de armazenamento horizontal.

O Papel do RDW

Consome dados já limpos do Lake, aplica estrutura rígida (Schema-on-write) e serve relatórios de alta velocidade com segurança.

A Evolução Integrada: Data Fabric

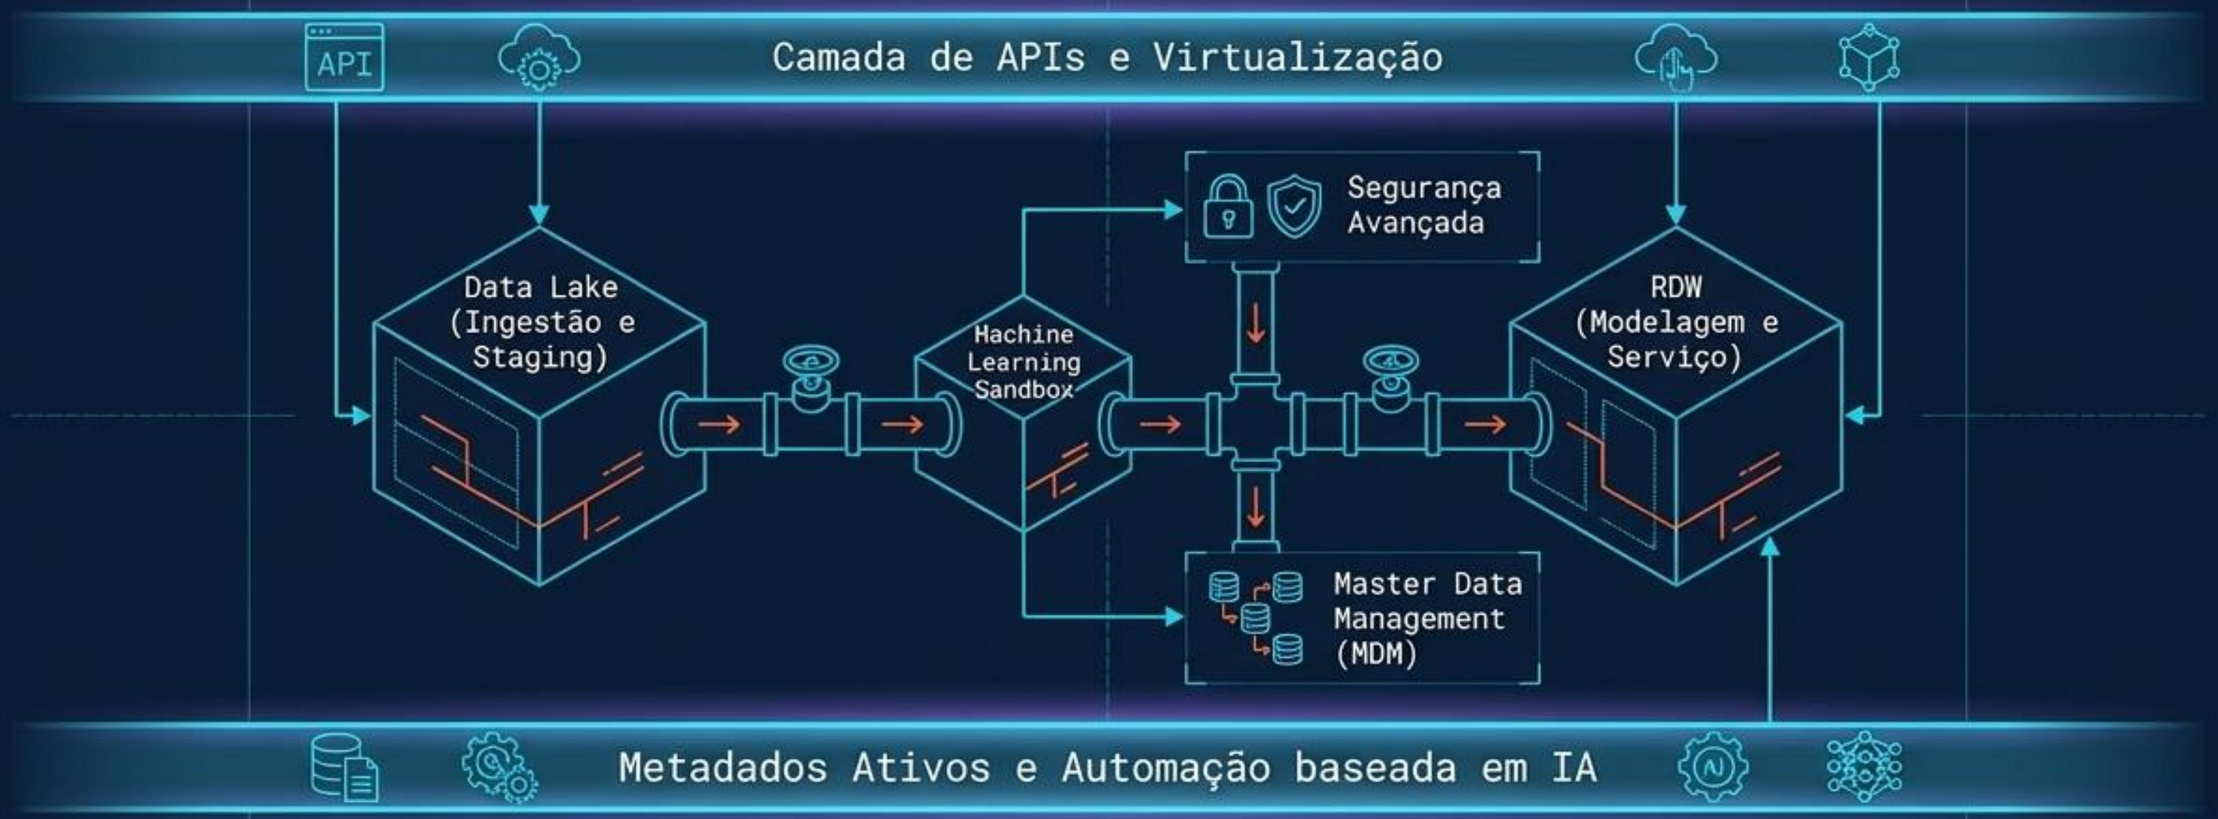

1

Catálogo de Metadados:
O sistema descobre automaticamente onde cada dado reside.

2

Virtualização:
Permite consultas rápidas sem a necessidade de mover fisicamente os dados.

3

MDM:
Cria uma única versão da verdade (ex: O que define um "Cliente" em toda a empresa).

A Unificação: Data Lakehouse

A Mágica Transacional

Um repositório único. O software open-source é inserido sobre o lago caótico, trazendo propriedades ACID, evolução de esquema e "viagem no tempo" diretamente para os arquivos nativos. Fim da redundância e eliminação total do RDW.

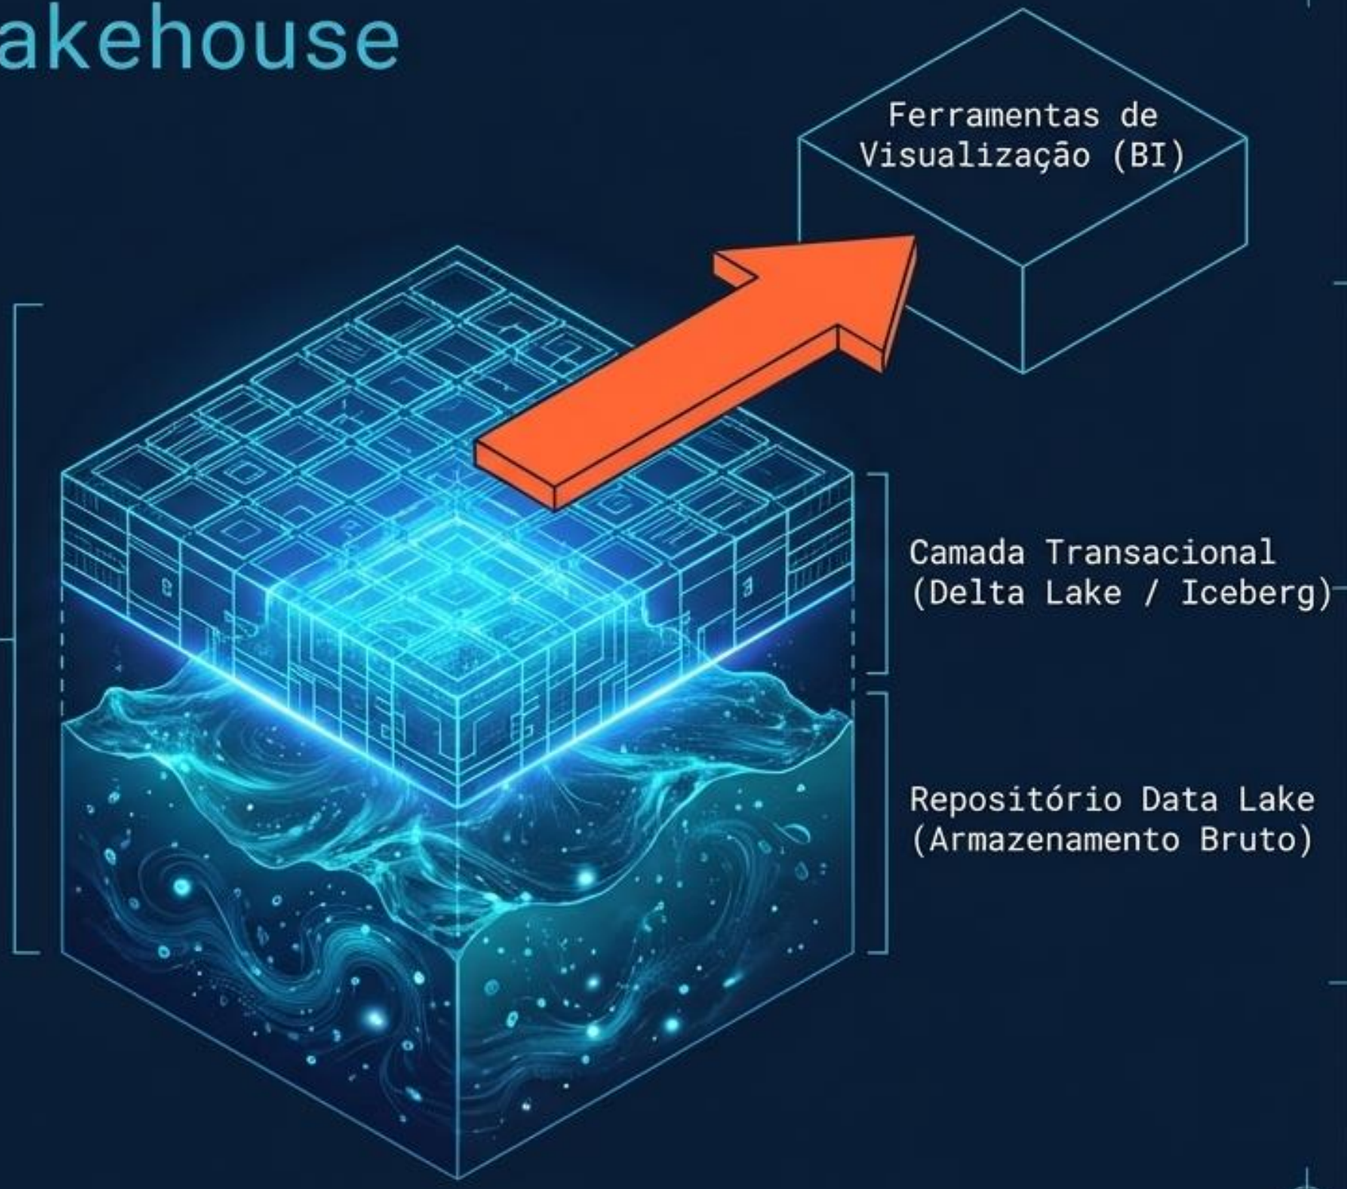

A Revolução Descentralizada: Data Mesh

O Gargalo Centralizado

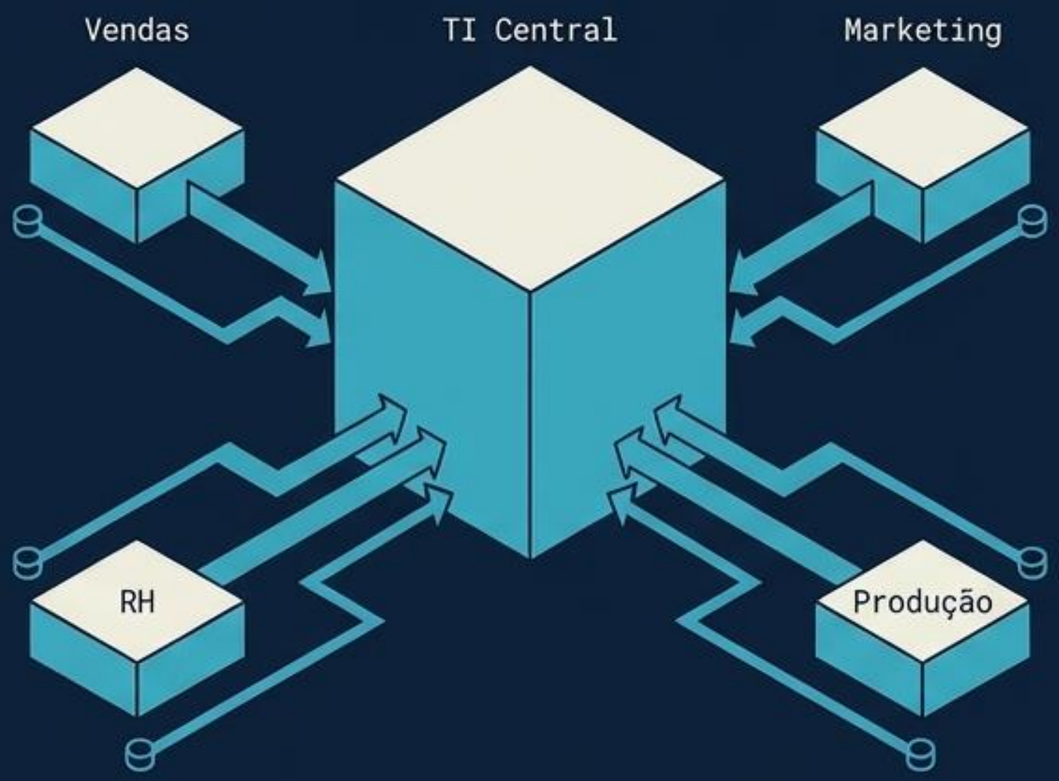

A Malha Descentralizada

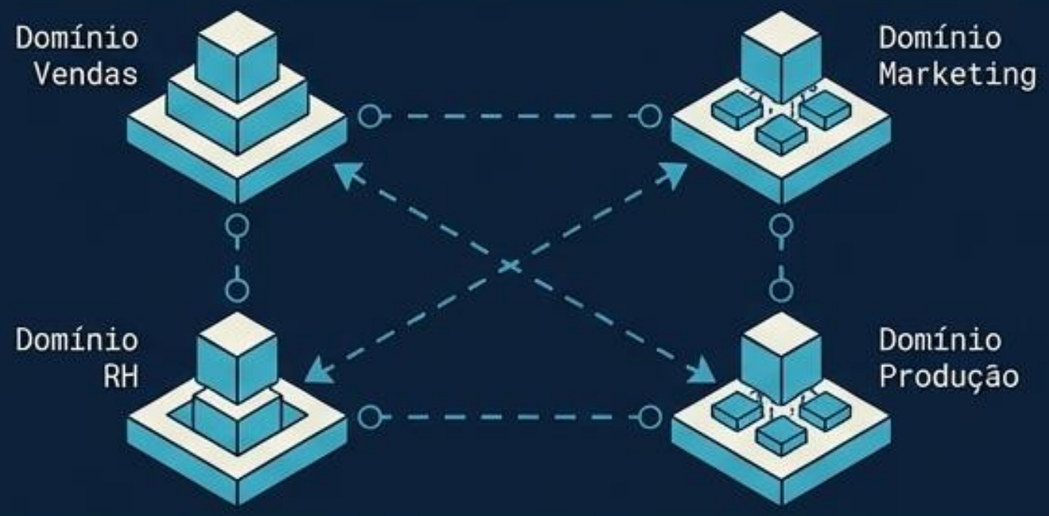

1. **Propriedade de Domínio:** Marketing gerencia seus dados; Finanças gerencia finanças.
2. **Dado como Produto:** Empacotado, documentado e servido com SLAs.
3. **Governança Federada:** Padrões globais de segurança aplicados em toda a rede.

.fatores decisórios

SÍNTESE: Matriz de Decisão Arquitetural

	RDW	Data Lake	MDW	Fabric	Lakehouse	Mesh
Maturidade da Tecnologia	100%	75%	75%	75%	75%	0%
Dificuldade de Desenvolvimento	25%	50%	50%	50%	75%	100%
Custo Total da Solução	100%	25%	50%	75%	50%	100%
Latência de Dados	25%	100%	25%	25%	75%	varies
Casos de Uso Suportados	25%	50%	50%	75%	100%	100%

NotebookLM

O Ponto de Convergência: Evitando Armadilhas de Hype

O Veredito:

A arquitetura certa não é a mais moderna; é a que se alinha aos casos de uso, ao orçamento e às habilidades da sua equipe atual.

Tentativas de saltar estágios resultam em fracassos milionários.

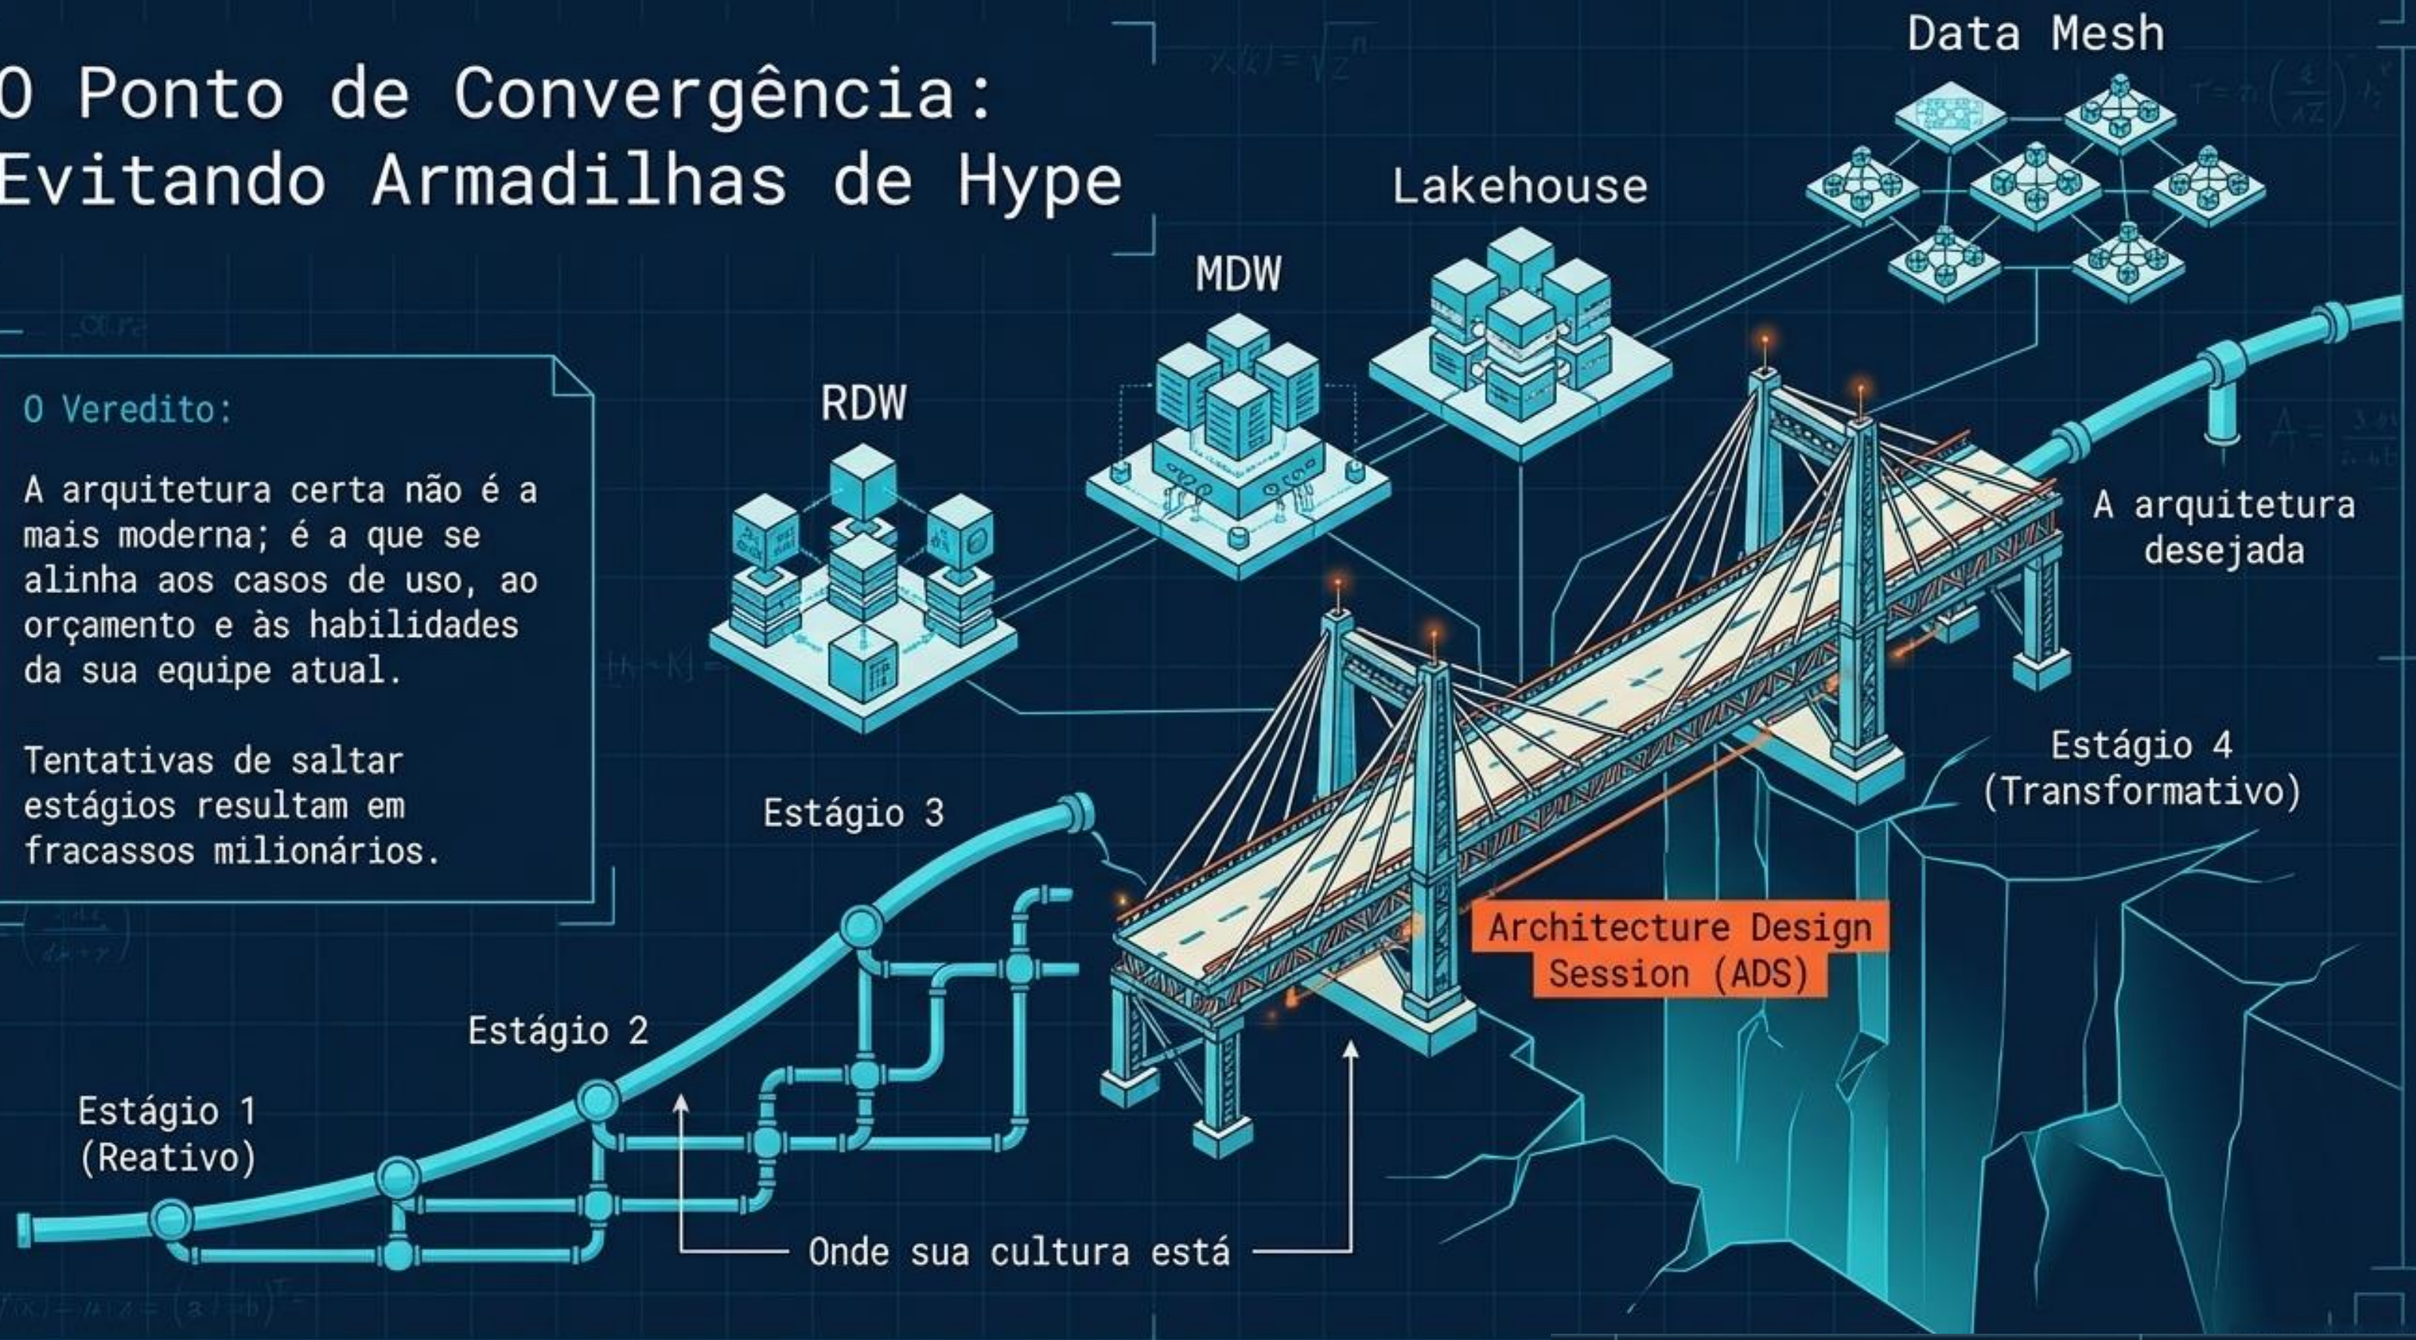

A Fase de Descoberta: Pergunte Antes de Comprar

Qual o nível de habilidade da equipe?

Determina a escolha entre ferramentas No-code ou infraestrutura baseada em Spark/Python.

Haverá dados não-relacionais ou streaming?

Impõe a necessidade obrigatória de uma zona Data Lake na arquitetura.

Existem SLAs estritos de milissegundos?

Molda a topologia de computação para relatórios de alta velocidade.

Qual o apetite para autoatendimento de BI?

Dita quão simplificado e mastigado o modelo de dados final deve ser entregue aos usuários.

Limitações de Soberania de Dados?

Pode forçar a quebra em múltiplos repositórios distribuídos geograficamente.

Decisão Arquitetural

O Blueprint Final: Da Teoria à Prática

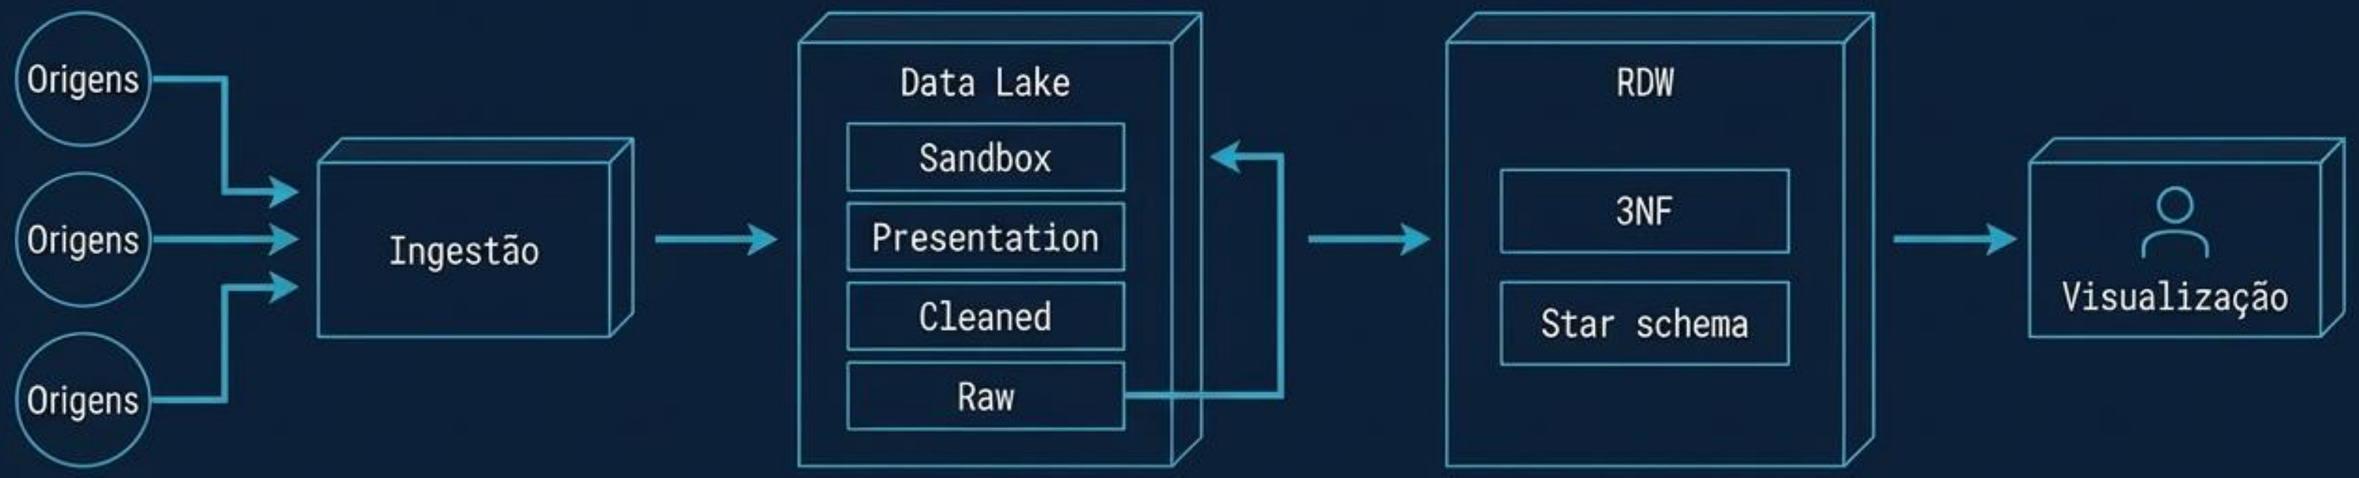

Objetivos Alcançados

BI de autoatendimento;
Redução de custos na nuvem;
Governança unificada.

Pontos de Dor Resolvidos

Fim do estresse nos sistemas operacionais;
Eliminação de atrasos;
Propriedade clara.

Próximos Passos

Configurar ambiente POC;
Provar integrações.

[O verdadeiro diferencial não reside na tecnologia escolhida, mas no rigor arquitetural do planejamento. O projeto da ponte deve vir sempre antes da concretagem.]

NotebookLM

Referências

SERRA, James. Deciphering Data Architectures: Choosing Between a Modern Data Warehouse, Data Fabric, Data Lakehouse, and Data Mesh. Sebastopol: O’Reilly Media, 2024.

Aplicação:

- Conteúdo de aula exclusivamente baseado na referência acima.

Obrigado!

© Todos os direitos reservados ao autor prof. Luiz Gustavo Dias | Conteúdo desenvolvido exclusivamente para aula do curso de Sistemas de Informação da UNIVÁS.