ETL

KIMBALL FRAMEWORK

Prof. Gustavo Dias

O processo de Extração, Transformação e Carga (ETL) é um dos pilares da modelagem dimensional, segundo Ralph Kimball. A implementação eficaz do ETL deve considerar uma série de características essenciais para garantir a qualidade, segurança e eficiência dos dados utilizados em Business Intelligence (BI). Abaixo, discutimos cada um dos principais aspectos a serem observados no desenho de um processo ETL robusto.

1. Necessidades do Negócio

Antes de iniciar o desenvolvimento do ETL, é essencial compreender os requisitos do negócio. Isso inclui a identificação dos principais indicadores de desempenho (KPIs), requisitos analíticos e objetivos estratégicos da organização. O entendimento correto dessa fase garante que as transformações realizadas nos dados suportem decisões empresariais.

2. Compliance

Os processos ETL devem seguir normativas e regulamentações aplicáveis ao setor, como LGPD, GDPR e outras leis de proteção de dados. Isso exige auditoria, trilhas de auditoria e registros de acesso, além de políticas de retenção e descarte seguras.

3. Data Quality

A qualidade dos dados é crítica para a confiabilidade das análises. Um bom processo ETL deve implementar métodos de padronização, deduplicagem, limpeza e validação dos dados. Algoritmos de perfis de dados e controles de consistência devem ser utilizados para evitar inconsistências e falhas na análise.

4. Segurança

A segurança dos dados durante o processo ETL deve ser garantida por criptografia, controle de acessos, mascaramento de dados sensíveis e segregação de ambientes de produção e testes. A implementação de logs de acesso também é necessária para rastreamento e conformidade regulatória.

5. Data Integration

O ETL deve integrar dados de diversas fontes, sejam elas bancos relacionais, arquivos CSV, APIs ou sistemas legados. Para isso, é necessário estabelecer mapeamentos, regras de transformação e controle de chaves para garantir unicidade e consistência dos dados.

6. Data Latency

A latência de dados é um fator importante a ser considerado. Dependendo dos requisitos do negócio, o ETL pode operar em lotes (batch) ou em tempo real

(streaming). A otimização da carga deve equilibrar o volume de dados, o tempo de processamento e a disponibilidade dos recursos computacionais.

7. Arquivamento

O armazenamento e arquivamento de dados históricos é fundamental para auditorias e análises retrospectivas. Definir políticas de arquivamento, retenção e purga de dados garante que o sistema mantenha desempenho adequado sem desperdício de recursos.

8. Interfaces de BI

Os dados processados pelo ETL devem ser disponibilizados de maneira intuitiva para ferramentas de BI e relatórios analíticos. Isso inclui a definição de esquemas, metadados claros e documentação para facilitar o uso por analistas e tomadores de decisão.

9. Habilidades Disponíveis

A complexidade do ETL requer profissionais qualificados em modelagem de dados, SQL, ferramentas ETL (como Talend, SSIS, Apache Nifi) e soluções em nuvem. A capacitação da equipe é um diferencial para garantir a manutenção e evolução do processo.

Subsistemas ETL

O processo ETL (Extract, Transform, Load) segundo Kimball é composto por diversos subsistemas que garantem a extração, limpeza, conformidade, entrega e gestão dos dados no Data Warehouse (DW). Abaixo, detalhamos cada um desses subsistemas e suas respectivas funções:

Extração: recebendo dados no DW

A extração dos dados é o primeiro passo do processo ETL e envolve a identificação, captura e importação de dados de diferentes fontes.

Data Profiling: Analisa a estrutura e a qualidade dos dados antes da extração para entender padrões e inconsistências.

Change Data Capture System: Identifica e captura apenas as alterações ocorridas nos dados desde a última extração, otimizando o processo.

Extract System: Extrai os dados de fontes heterogêneas, garantindo que a coleta seja eficiente e confiável.

Cleaning and Conforming Data

O processo de limpeza e conformidade garante que os dados sejam corrigidos, padronizados e preparados para integração ao DW.

Data Cleansing System: Identifica e corrige erros nos dados extraídos, como valores inconsistentes ou ausentes.

Error Event Schema: Documenta e gerencia os erros identificados para análise e auditoria.

Audit Dimension Assembler: Permite rastrear alterações e auditar o processo ETL para garantir confiabilidade.

Deduplication System: Elimina registros duplicados para manter a consistência dos dados.

Conforming System: Garante que os dados sigam padrões comuns, permitindo integração entre diferentes fontes.

Delivering: Prepare for Presentation

Esta fase prepara os dados para a apresentação e análise nos sistemas de BI (Business Intelligence).

Slowly Changing Dimension Manager: Gerencia a evolução das dimensões para refletir mudanças ao longo do tempo.

Surrogate Key Generator: Cria chaves substitutas para facilitar a integração de dados.

Hierarchy Manager: Mantém e manipula hierarquias dentro do DW.

Special Dimensions Manager: Gerencia dimensões complexas que exigem tratamentos específicos.

Fact Table Builders: Constrói tabelas de fatos consolidando dados transacionais.

Surrogate Key Pipeline: Facilita a geração de chaves substitutas em processos paralelos.

Multivalued Dimension Bridge Table Builder: Trata relações complexas entre dimensões e fatos.

Late Arriving Data Handler: Gerencia dados que chegam atrasados ao sistema.

Dimension Manager System: Controla e gerencia as dimensões dentro do DW.

Fact Provider System: Garante a entrega de tabelas de fatos para consulta.

Aggregate Builder: Cria agregados para otimizar consultas e melhorar a performance.

OLAP Cube Builder: Gera cubos OLAP para análise multidimensional.

Data Propagation Manager: Controla a disseminação dos dados para diferentes sistemas de análise.

Managing the ETL Environment

A gestão do ambiente ETL é essencial para garantir a continuidade, segurança e monitoramento do processo.

Job Scheduler: Gerencia a execução dos processos ETL de acordo com cronogramas.

Backup System: Mantém cópias de segurança dos dados e processos ETL.

Recovery and Restart System: Permite a recuperação de falhas e a reinicialização de processos ETL interrompidos.

Version Control System: Garante a rastreabilidade das versões dos processos ETL.

Version Migration System: Permite a migração entre diferentes versões do ETL.

Workflow Monitor: Monitora os processos ETL em execução.

Sorting System: Organiza e otimiza os dados para processamento eficiente.

Lineage and Dependency Analyzer: Analisa a linhagem e dependências entre os dados.

Problem Escalation System: Gerencia a escalada de problemas detectados no ETL.

Parallelizing/Pipeline System: Garante a execução paralela dos processos ETL para maior eficiência.

Security System: Implementa mecanismos de segurança para proteger os dados.

Compliance Manager: Assegura que os processos ETL estejam em conformidade com regulamentos e normas.

Metadata Repository Manager: Administra o repositório de metadados, garantindo o rastreamento e documentação dos dados.

Modelo de Framework para Condução do Processo ETL

Com base nesses subsistemas, um framework ideal para a condução do processo ETL deve incluir:

- Um módulo de extração com perfilamento e captura eficiente de dados.
- Um mecanismo robusto de limpeza e conformidade para garantir integridade.
- Estruturas flexíveis para entrega, incluindo suporte a OLAP e análise multidimensional.
- Mecanismos de gerenciamento, abrangendo segurança, versão e automação de execução.

Referência

KIMBALL, Ralph; ROSS, Margy. The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling. 3. ed. Indianapolis: Wiley, 2013.